# 数据挖掘作业1

2017326603075 陈浩骏 17信科1班

## 说明

- 选用 MySQL57(docker) 做数据库, 可视化部件为 pyecharts on Python3.
- 原表结构 ./NorthwindData/northwind.sql 经
   过 ./NorthwindData/ripChineseColumnName.sql 修改,将列名表名均更名为ASCII字符集内能够表示的字符.

## 作业1.1

### 输出一张大表

所含信息有订单ID,产品ID,客户ID,雇员ID,供应商ID,时间ID,运货商,货主城市,单价高低(50一个等级),订单数,订单金额,商品数

```
USE northwind;
# TODO: 订单量为主键, 订单数为列不合理, ditched corresponding column
#输出一张大表,所含信息有订单ID,产品ID,客户ID,雇员ID,供应商ID,时间ID,运货商,货主城市,
单价高低(50一个等级),订单数,订单金额,商品数
DROP VIEW IF EXISTS vOrderGlance;
CREATE VIEW vOrderGlance AS
                      AS '订单ID',
SELECT tOrder.orderID
      group_concat(tProduct.productID) AS '涉及产品ID',
      group_concat(tProduct.pName) AS '涉及产品名',
                           AS '顾客ID',
      tOrder.customerID
      group_concat(tProduct.supplierID) AS '涉及供货商ID',
      date_format(tOrder.orderDate, '%Y-%m-%d')
                                               AS '订单日期',
      tDeliveryCompany.dCompanyName
                                     AS '送货公司',
                        AS '货主城市',
      tOrder.ownerCity
      cast(sum(tOrderDetail.productPrice * tOrderDetail.productCount
          * (1 - tOrderDetail.productDiscount)) AS DECIMAL(10, 2))
          AS '订单总价',
      count(tOrderDetail.productID) AS '涉及商品数'
FROM torder,
    tOrderDetail,
    tProduct.
    tDeliveryCompany
WHERE tProduct.productID = tOrderDetail.productID
 AND tOrderDetail.orderID = tOrder.orderID
 AND tOrder.deliveryCompany = tDeliveryCompany.DeliveryCompanyID
GROUP BY tOrder.orderID;
```

	顕订单ID: 闡涉及产品ID:	■涉及产品名:	■顾客ID:	■涉及供货商ID	: ■订单日期 :	■送货公司:	■÷	■ 订单总价:	驅 涉及商品数:
1	10248 72,17,42	酸奶酪,猪肉,糙	VINET	14,7,20	1996-07-04	联邦货运	北京	440.00	3
2	10249 51,14	猪肉干,沙茶	TOMSP	24,6	1996-07-05	急速快递	济南	1863.40	2
3	10250 65,41,51	海苔酱,虾子,猪	HANAR	2,19,24	1996-07-08	统一包裹	秦皇岛	1552.60	3
4	10251 57,65,22	小米,海苔酱,糯	VICTE	26,2,9	1996-07-08	急速快递	南京	654.06	3
5	10252 20,33,60	桂花糕,浪花奶香	SUPRD	8,15,28	1996-07-09	统一包裹		3597.90	3
6	10253 49,31,39	薯条,温馨奶酪,	HANAR	23,14,18	1996-07-10	统一包裹		1444.80	3
7	10254 55,74,24	鸭肉,鸡精,汽水	CHOPS	25,4,10	1996-07-11	统一包裹	武汉	556.62	3
8	10255 2,59,16,36	牛奶,苏澳奶酪,	RICSU	1,28,7,17	1996-07-12	联邦货运	北京	2490.50	4
9	10256 77,53	辣椒粉,盐水鸭	WELLI	12,24	1996-07-15	统一包裹	济南	517.80	2
10	10257 39,77,27	运动饮料,辣椒粉	HILAA	18,12,11	1996-07-16	联邦货运		1119.90	3
11	10258 5,32,2	麻油,白奶酪,牛	ERNSH	2,14,1	1996-07-17	急速快递	济南	1614.88	3
12	10259 21,37		CENTC	8,17	1996-07-18	联邦货运		100.80	2
13	10260 62,41,70,57	山渣片,虾子,苏	OTTIK	29,19,7,26	1996-07-19	急速快递	北京	1504.65	4
14	10261 35,21	蜜桃汁,花生	QUEDE	16,8	1996-07-19	统一包裹	济南	448.00	2
15	10262 7,56,5	海鲜粉,白米,麻	RATTC	3,26,2	1996-07-22	联邦货运	上海	584.00	3
16	10263 16,74,24,30	饼干,鸡精,汽水	ERNSH	7,4,10,13	1996-07-23	联邦货运	北京	1873.80	4
17	10264 41,2		F0LK0	19,1	1996-07-24	联邦货运	北京	695.62	2
18	10265 70,17	苏打水,猪肉	BLONP	7,7	1996-07-25	急速快递	武汉	1176.00	2
19	10266 12	德国奶酪	WARTH	5	1996-07-26	联邦货运	北京	346.56	1

# 作业1.2

输出销售额前十大客户的基本信息

## SQL语句实现

#### **Glance**

Using PyCharm/DataGrip -> Database -> Export to -> Markdown Pycharm/DataGrip -> 数据库 -> 导出至 -> Markdown

顾客ID	顾客名	总流水
QUICK	高上补习班	110277.30
ERNSH	正人资源	104874.98
SAVEA	大钰贸易	104361.95
RATTC	学仁贸易	51097.80
HUNGO	师大贸易	49979.90
HANAR	实翼	32841.37
KOENE	永业房屋	30908.38
FOLKO	五洲信托	29567.56
MEREP	华科	28872.19
WHITC	椅天文化事业	27363.60

# 输出平均订单单价最高(总额/订单数)客户的基本信息;

## SQL语句实现

```
SELECT tCustomer.customerID
                      AS '顾客ID',
       tCustomer.cCompanyName
                      AS '顾客名',
       sum(tOrderDetail.productCount * tOrderDetail.productPrice * (1 -
tOrderDetail.productDiscount)) AS '总流水',
       count(tOrder.customerID)
                      AS '单量',
       sum(tOrderDetail.productCount * tOrderDetail.productPrice * (1 -
tOrderDetail.productDiscount)) /
       count(tOrder.customerID)
                      AS '平均价'
FROM tCustomer,
     tOrder,
     tOrderDetail
WHERE tCustomer.customerID = tOrder.customerID
  AND tOrder.orderID = tOrderDetail.orderID
GROUP BY tCustomer.customerID
ORDER BY 平均价 DESC
LIMIT 10;
```

#### **Glance**

	■顾客ID	÷	■顾客名	<b>‡</b>	■总流水;	■单量÷	■平均价;
1	QUICK		高上补习班		110277.30488350891	86	1282.294242831499
2	SIMOB		百达电子		16817.097494864836	15	1121.1398329909891
3	ERNSH		正人资源		104874.97835350106	102	1028.1860622892261
4	HANAR		实翼		32841.36997813582	32	1026.2928118167445
5	PICCO		顶上系统		23128.859954281896	23	1005.6026067079085
6	HUNGO		师大贸易		49979.90494634077	55	908.7255444789231
7	MEREP		华科		28872.189950353655	32	902.2559359485517
8	SAVEA		大钰贸易		104361.94986812412	116	899.6719816217596
9	GREAL		仪和贸易		18507.44997683935	22	841.2477262199704
10	KOENE		永业房屋		30908.383968844264	39	792.5226658678016

## 输出库存不足三天销售的预警商品;

## SQL语句实现

```
# @-> Session-Wide Variable
SET @DAYSDIFF = 0;
SELECT to_days(max(tOrder.orderDate)) - to_days(min(tOrder.orderDate))
FROM torder
INTO @DAYSDIFF;
SELECT tProduct.productID,
      tProduct.pName AS '商品名',
      tProduct.pStorage AS '库存量',
      sum(tOrderDetail.productCount) / @DAYSDIFF AS '日销量',
      sum(tOrderDetail.productCount) / @DAYSDIFF * 3 > tProduct.pStorage
      AS '库存告急'
FROM tProduct,
    tOrderDetail
WHERE tOrderDetail.productID = tProduct.productID
GROUP BY tProduct.productID
ORDER BY 库存告急 DESC
LIMIT 100;
```

#### **Glance**

**Export using Method Mentioned Above** 

productID	商品名	库存量	日销量	库存告急
17	猪肉	0	1.4754	1
31	温馨奶酪	0	2.0820	1
53	盐水鸭	0	1.0760	1
29	鸭肉	0	1.1118	1
21	花生	3	1.5142	1
5	麻油	0	0.4441	1

## 输出订单最多的优秀雇员信息;

#### SQL语句实现

#### **Glance**

员工号	员工姓名	总单量
4	郑建杰	154
3	李芳	127
1	张颖	124
8	刘英玫	104
2	王伟	96
7	金士鹏	72
6	孙林	67
9	张雪眉	44
5	赵军	42

## 输出订单总金额的随时间变化图;

```
xDate = []
ySellAmount = []
ySellAmountSum = []
with open('queryResult/SELECT_year_tOrder_orderDate_.csv', 'r', encoding='utf-8') as f:
    f.readline() # 跳表头
```

```
for row in csv.reader(f):
        xDate.append('{}-{}'.format(row[0], row[1]))
        ySellAmount.append(round(float(row[2]), 0))
ySellAmountSum.append(ySellAmount[0])
for index in range(1, len(ySellAmount)):
ySellAmountSum.append(ySellAmountSum[len(ySellAmountSum)-1]+ySellAmount[index])
graph1 = (
   Line(init_opts=opts.InitOpts(width="1600px", height="800px"))
    .add_xaxis(xDate)
    .add_yaxis("总销量", ySellAmountSum, is_smooth=True)
    .set_global_opts(title_opts=opts.TitleOpts(title="销量总金额"))
)
graph2 = (
   Bar(
        init_opts=opts.InitOpts(
            animation_opts=opts.AnimationOpts(
                animation_delay=1000, animation_easing="elasticOut"
            ), width="1600px", height="800px"
        )
   )
    .add_xaxis(xDate)
    .add_yaxis("每月销售量", ySellAmount)
    .set_global_opts(title_opts=opts.TitleOpts(title="每月销售金额"))
)
```

见后

输出商品销量的特征;即什么商品畅销,什么商品滞销;

```
SELECT tProduct.productID,
       tProduct.pName
                                                 AS '商品名',
       sum(tOrderDetail.productCount) / @DAYSDIFF AS '日销量'
FROM tProduct,
    tOrderDetail
WHERE tOrderDetail.productID = tProduct.productID
GROUP BY tProduct.productID
ORDER BY 日销量 DESC
LIMIT 30;
# 输出商品销量的特征
SELECT tCategory.categoryName AS '类目', count(tOrderDetail.productID) AS '销量'
FROM tCategory,
    tOrderDetail,
     tProduct
WHERE tOrderDetail.productID = tProduct.productID
 AND tProduct.categoryID = tCategory.categoryID
GROUP BY categoryName
ORDER BY 销量 DESC;
```

productID	商品名	日销量
60	花奶酪	2.3502
59	苏澳奶酪	2.2295
31	温馨奶酪	2.0820
56	白米	1.8838
16	饼干	1.7258

类目	销量
饮料	405
日用品	365
点心	336
海鲜	330
调味品	214
谷类/麦片	197
肉/家禽	174
特制品	136

# 货主城市分析特征;

```
SELECT torder.ownerRegion AS '地区', count(torder.ownerName) AS '频数' FROM torder GROUP BY ownerRegion ORDER BY 频数 DESC;

# 货主城市分析特征;
SELECT torder.ownerCity AS '城市', count(torder.ownerCity) AS '频数' FROM torder GROUP BY ownerCity ORDER BY 频数 DESC;
```

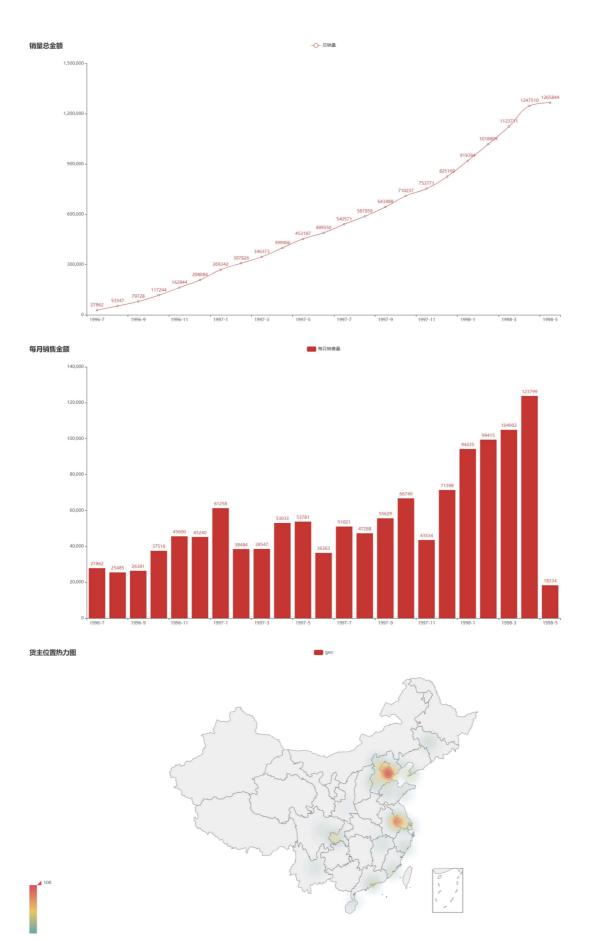
```
xCity = []
yCityCount = []
with open('queryResult/SELECT_tOrder_ownerCity_AS_count_t.csv', 'r',
encoding='utf-8') as f:
    f.readline()
    for row in csv.reader(f):
        xCity.append(row[0])
        yCityCount.append(int(row[1]))
```

```
graph3 = (
    Geo(init_opts=opts.InitOpts(width="1600px", height="800px"))
        .add_schema(maptype="china")
        .add(
        "geo",
        [list(z) for z in zip(xCity, yCityCount)],
        type_=ChartType.HEATMAP,
)
        .set_series_opts(label_opts=opts.LabelOpts(is_show=True))
        .set_global_opts(
        visualmap_opts=opts.VisualMapOpts(),
        title_opts=opts.TitleOpts(title="货主位置热力图"),
)
)
```

地区	频数
华北	355
华东	236
华南	85
西南	81
东北	65

城市	频数
天津	207
南京	85
北京	52
重庆	46
石家庄	40

可视化详见./NorthWindData/Visualization.py与可视化.html



全库数据导出SQL文件位于 NorthWindData/FULLExport.sql

# 附加

此外加入了 ./ExtraData 的数据分析, 利用 ./ExtraData/SalesDataInit.py 以 sqlalchemy 做ORM 框架, 生成了下列表结构的100万行销售数据, 可视化具体见 ./ExtraData 目录中

